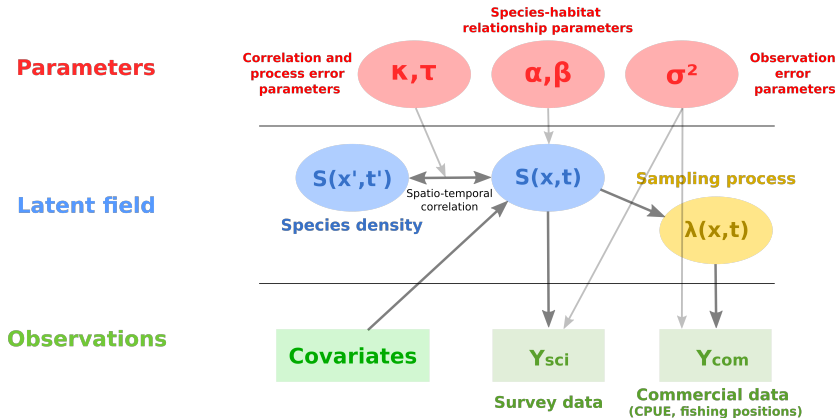


TD R-INLA - M2 halieutes

Baptiste Alglave based on Thomas Opitz and Denis Allard


Janvier 2022

Modèle hiérarchique spatial



Un exemple de modèle hiérarchique

Champ gaussien



$$x|\theta \sim GF(\mu, \Sigma) \quad \text{champ gaussien}$$

- $\Sigma = Q^{-1}$: la matrice de variance-covariance de l'effet aléatoire (suit une certaine fonction de variance-covariance - souvent de type Matérn). Q est la matrice de précision.

Formulation mathématique

$$\theta \sim \pi(\theta) \quad \text{hyperparamètres}$$

$$x|\theta \sim GF(0, \Sigma) \quad \text{champ gaussien latent}$$

$$y|x, \theta \sim \prod_i \pi(y_i | \eta_i(x), \theta) \quad \text{processus d'observation}$$

- y : les observations
- θ : les hyperparamètres
- $\Sigma = Q^{-1}$: la matrice de variance-covariance de l'effet aléatoire (suit une certaine fonction de variance-covariance - souvent de type Matérn). Q est la matrice de précision.
- $\eta(x) = Ax$ un processus gaussien avec A la matrice d'observation

La difficulté : estimer la structure de corrélation spatiale (Σ ou Q).

Formulation mathématique

$$\theta \sim \pi(\theta) \quad \text{hyperparamètres}$$

$$x|\theta \sim GF(0, \Sigma) \quad \text{champ gaussien latent}$$

$$y|x, \theta \sim \prod_i \pi(y_i | \eta_i(x), \theta) \quad \text{processus d'observation}$$

- y : les observations
- θ : les hyperparamètres
- $\Sigma = Q^{-1}$: la matrice de variance-covariance de l'effet aléatoire (suit une certaine fonction de variance-covariance - souvent de type Matérn). Q est la matrice de précision.
- $\eta(x) = Ax$ un processus gaussien avec A la matrice d'observation

La difficulté : estimer la structure de corrélation spatiale (Σ ou Q).

1er approximation : Approche SPDE

- Principe de l'approche SPDE (Lindgren, Rue and Lindström, 2011) :
 - 1 champ gaussien de covariance une fonction de Matérn ...
 - ... est solution de l'EDPS ...

$$(\kappa^2 - \Delta)^{\alpha/2} x(s) = W(s), \quad s \in \mathbb{R}^d, \quad \alpha = \nu + d/2, \quad \kappa > 0, \quad \nu > 0$$

- ... et peut être représenté comme un champ Gauss-Markov (seulement pour certaines valeurs de ν)
- Ce lien entre champ Gaussien et champ Gauss-Markov fournit une représentation creuse de l'effet spatial et simplifie les calculs.

Notations : Δ le laplacien, $W(s)$ un bruit blanc gaussien, κ le paramètre contrôlant la portée de l'effet aléatoire, ν et α les paramètres de lissage, d le nombre de dimension (2).

Pour des valeurs données de ν , les champs Gauss-Markov génèrent des solutions approchées de l'EDPS. Les matrices de précisions de ces champs Gauss-Markov peuvent être utilisées pour formuler les matrices de précisions des champs gaussiens. Par exemple :

- pour $\nu = 1$, la matrice de précision s'écrit :

$$\begin{pmatrix} 1 & & \\ -2a & 2 & \\ 4 + a^2 & -2a & 1 \end{pmatrix}$$

- pour $\nu = 2$:

$$\begin{pmatrix} -1 & & & & \\ 3a & -3 & & & \\ -3(a^2 + 3) & 6a & -3 & & \\ a(a^2 + 12) & -3(a^2 + 3) & 3a & -1 & \end{pmatrix}$$

- La matrice est de moins en moins creuse ; l'effet aléatoire en un point dépend d'un voisinage plus étendu.

Pour des valeurs données de ν , les champs Gauss-Markov génèrent des solutions approchées de l'EDPS. Les matrices de précisions de ces champs Gauss-Markov peuvent être utilisées pour formuler les matrices de précisions des champs gaussiens. Par exemple :

- pour $\nu = 1$, la matrice de précision s'écrit :

$$\begin{pmatrix} 1 & & \\ -2a & 2 & \\ 4 + a^2 & -2a & 1 \end{pmatrix}$$

- pour $\nu = 2$:

$$\begin{pmatrix} -1 & & & & \\ 3a & -3 & & & \\ -3(a^2 + 3) & 6a & -3 & & \\ a(a^2 + 12) & -3(a^2 + 3) & 3a & -1 & \end{pmatrix}$$

- La matrice est de moins en moins creuse ; l'effet aléatoire en un point dépend d'un voisinage plus étendu.

Pour des valeurs données de ν , les champs Gauss-Markov génèrent des solutions approchées de l'EDPS. Les matrices de précisions de ces champs Gauss-Markov peuvent être utilisées pour formuler les matrices de précisions des champs gaussiens. Par exemple :

- pour $\nu = 1$, la matrice de précision s'écrit :

$$\begin{pmatrix} 1 & & \\ -2a & 2 & \\ 4 + a^2 & -2a & 1 \end{pmatrix}$$

- pour $\nu = 2$:

$$\begin{pmatrix} -1 & & & & \\ 3a & -3 & & & \\ -3(a^2 + 3) & 6a & -3 & & \\ a(a^2 + 12) & -3(a^2 + 3) & 3a & -1 & \end{pmatrix}$$

- La matrice est de moins en moins creuse ; l'effet aléatoire en un point dépend d'un voisinage plus étendu.

Pour des valeurs données de ν , les champs Gauss-Markov génèrent des solutions approchées de l'EDPS. Les matrices de précisions de ces champs Gauss-Markov peuvent être utilisées pour formuler les matrices de précisions des champs gaussiens. Par exemple :

- pour $\nu = 1$, la matrice de précision s'écrit :

$$\begin{pmatrix} 1 & & \\ -2a & 2 & \\ 4 + a^2 & -2a & 1 \end{pmatrix}$$

- pour $\nu = 2$:

$$\begin{pmatrix} -1 & & & & \\ 3a & -3 & & & \\ -3(a^2 + 3) & 6a & -3 & & \\ a(a^2 + 12) & -3(a^2 + 3) & 3a & -1 & \end{pmatrix}$$

- La matrice est de moins en moins creuse ; l'effet aléatoire en un point dépend d'un voisinage plus étendu.

Fig. 2 *Left panel:* locations of the 24 monitoring stations in Piemonte region. *Right panel:* triangulation of Piemonte region using 123 vertices





Fig. 3 *Left panel:* example of a spatial random field (*left*) given by $X(s) = \cos(s_1) + \sin(s_2)$, where $s = \{s_1, s_2\}$. *Right panel:* corresponding finite element representation of the spatial random field $X(s)$ according to Eq. (9)

2e approximation : INLA

La probabilité conjointe du champ latent et des hyperparamètres s'écrit :

$$\pi(x, \theta | y) \propto \pi(\theta) \pi(x | \theta) \pi(y | x, \theta) \propto \pi(\theta) \pi(x | \theta) \prod_{i \in \mathcal{I}} \pi(y_i | x_i, \theta)$$

avec θ : les paramètres, x : le champ latent, y : les observations

→ Long à estimer (via des méthodes type MCMC)

La méthode INLA consiste à approximer les distributions marginales

$\pi(\theta | y)$ et $\pi(x_i | \theta, y)$:

- $\tilde{\pi}(x_i | y) = \int \tilde{\pi}(x_i | \theta, y) \tilde{\pi}(\theta | y) d\theta$
- $\tilde{\pi}(\theta_j | y) = \int \tilde{\pi}(\theta | y) d\theta_{-j}$

2e approximation : INLA

La probabilité conjointe du champ latent et des hyperparamètres s'écrit :

$$\pi(x, \theta | y) \propto \pi(\theta) \pi(x | \theta) \pi(y | x, \theta) \propto \pi(\theta) \pi(x | \theta) \prod_{i \in \mathcal{I}} \pi(y_i | x_i, \theta)$$

avec θ : les paramètres, x : le champ latent, y : les observations

→ Long à estimer (via des méthodes type MCMC)

La méthode INLA consiste à approximer les distributions marginales

$\pi(\theta | y)$ et $\pi(x_i | \theta, y)$:

- $\tilde{\pi}(x_i | y) = \int \tilde{\pi}(x_i | \theta, y) \tilde{\pi}(\theta | y) d\theta$
- $\tilde{\pi}(\theta_j | y) = \int \tilde{\pi}(\theta | y) d\theta_{-j}$

2e approximation : INLA

La probabilité conjointe du champ latent et des hyperparamètres s'écrit :

$$\pi(x, \theta|y) \propto \pi(\theta)\pi(x|\theta)\pi(y|x, \theta) \propto \pi(\theta)\pi(x|\theta) \prod_{i \in \mathcal{I}} \pi(y_i|x_i, \theta)$$

avec θ : les paramètres, x : le champ latent, y : les observations

→ **Long à estimer (via des méthodes type MCMC)**

La méthode INLA consiste à approximer les distributions marginales

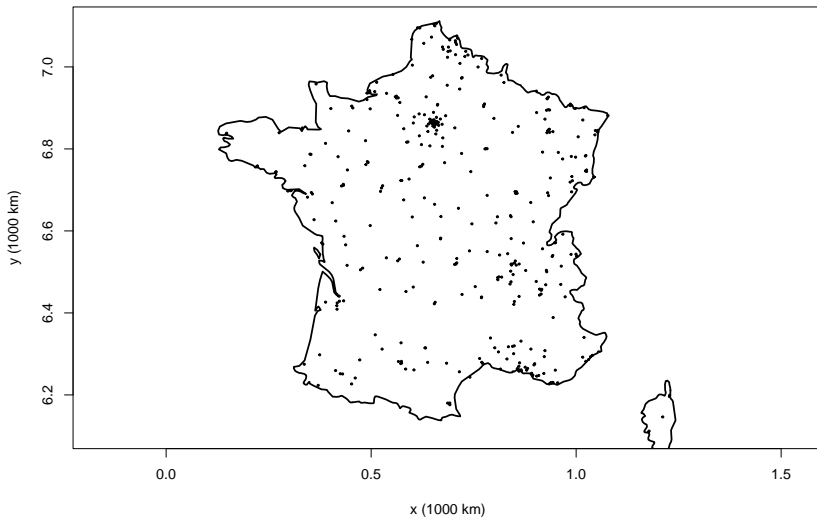
$\pi(\theta|y)$ et $\pi(x_i|\theta, y)$:

- $\tilde{\pi}(x_i|y) = \int \tilde{\pi}(x_i|\theta, y) \tilde{\pi}(\theta|y) d\theta$
- $\tilde{\pi}(\theta_j|y) = \int \tilde{\pi}(\theta|y) d\theta_{-j}$


Bilan

- INLA : Estimation des lois marginales des effets aléatoires et des hyperparamètres par des approximations de Laplace emboîtées
- Approche SPDE (1er résultats) : Approximation d'un champ gaussien par un champ Gauss-Markov
 - Valide pour des champs latents gaussiens
- Approche SPDE (2e résultats) : Interpolation linéaire pour relier le champ gaussien (définie sur une maille discrète) aux observations (définies sur un domaine continu)
 - Attention à la construction de la maille

Données



Création de la mesh



Construction de l'objet SPDE

```
mypde=inla.spde2.pcmatern(mesh=mesh,  
                           alpha=2,  
                           prior.range=c(.01,.1),  
                           prior.sigma=c(25,0.5))  
  
# Matrice d'observation pour faire le lien  
# entre les noeuds de la mesh et les points d'observation  
A=inla.spde.make.A(mesh,loc=xy_OBS)  
  
# Vecteur des indices pour les noeuds de la mesh  
idx.spatial=inla.spde.make.index("spatial",  
                                  n.spde=mesh$n)
```

Construction du modèle de régression

Premièrement, on construit un dataframe de covariable.

```
covar.df=data.frame(intercept=1,
                     x=xy_OBS[,1],
                     y=xy_OBS[,2])

# Creation du stack pour les données et les indices
mystack=inla.stack(data=list(pm10=OBS_daily2014$PM10),
                  A=list(A,1),
                  effects=list(idx.spatial,covar.df))

# Ecriture des formules du modèle
myformula=pm10~-1+intercept+f(spatial,model=mypde)
```

N.b.: comme on écrit l'intercept de façon explicite, on doit inclure "-1" dans l'expression du modèle.

Ajustement du modèle avec R-INLA

```
fit=inla(myformula,
  data=inla.stack.data(mystack),
  family="gaussian",
  control.predictor=list(A=inla.stack.A(mystack),
                        compute=FALSE),
  control.inla=list(int.strategy="eb",
                   strategy="gaussian"),
  verbose=FALSE)

summary(fit)
```

```
##
## Call:
## c("inla(formula = myformula, family = \"gaussian\", data =
## inla.stack.data(mystack), \"\", \" verbose = FALSE, control.predictor =
## list(A = inla.stack.A(mystack), \"\", \" compute = TRUE, link = 1),
## control.inla = list(int.strategy = \"eb\", \"\", \" strategy =
## \"gaussian\"))")
## Time used:
## Pre = 0.832, Running = 99.7, Post = 8.58, Total = 109
## Fixed effects:
##      mean      sd 0.025quant 0.5quant 0.975quant  mode kld
## intercept 18.058 0.324      17.423   18.058      18.694 18.058   0
##
## Random effects:
##      Name      Model
##      spatial SPDE2 model
##
## Model hyperparameters:
##
##      mean      sd 0.025quant 0.5quant
## Precision for the Gaussian observations 0.009 0.000      0.009   0.009
## Range for spatial                      0.021 0.005      0.012   0.021
## Stdev for spatial                      4.326 0.392      3.655   4.289
##
##      0.975quant  mode
## Precision for the Gaussian observations      0.009 0.009
## Range for spatial                      0.031 0.021
## Stdev for spatial                      5.190 4.192
##
## Marginal log-Likelihood: -283189.30
## is computed
## Posterior summaries for the linear predictor and the fitted values are computed
## (Posterior marginals needs also 'control.compute=list(return.marginals.predictor=TRUE)')
```

Prédictions avec R-INLA

Pour calculer les prédictions, la donnée d'entrée (`inla.stack`) doit être un peu modifiée. On ajoute des valeurs NA au vecteur d'observations et INLA prédit les valeurs du champ latent sur ces points.

```
# Construction de la grille de projection
proj_grid=inla.mesh.projector(mesh,
                               xlim=range(bound$loc[,1]),
                               ylim=range(bound$loc[,2]),
                               dims=c(100,100))

xygrid=as.matrix(expand.grid(proj_grid$x,proj_grid$y))

# Construction la matrice de projection
A=inla.spde.make.A(mesh,
                   loc=rbind(xygrid,xy_OBS))


covar.df=data.frame(intercept=1,
                    x=c(xygrid[,1],
                        xy_OBS[,1]),
                    y=c(xygrid[,2],
                        xy_OBS[,2]))


# Creation du stack avec toutes les données et les indices: on ajoute des NA dans le vecteur d'observation
mystack=inla.stack(data=list(pm10=c(rep(NA,nrow(xygrid)),
                                     OBS_daily2014$PM10)),
                  A=list(A,1),
                  effects=list(idx.spatial,covar.df),
                  tag="mytag")
```

Lors de l'ajustement, on spécifie l'argument `compute=TRUE` (pour calculer les valeurs ajustées et les valeurs prédites) et `link=1`.


Le temps de calcul peut être beaucoup plus long puisque R-INLA calcule aussi les prédictions sur l'ensemble de la grille.

```
fit=inla(myformula,  
        data=inla.stack.data(mystack),  
        family="gaussian",  
        control.predictor=list(A=inla.stack.A(mystack),  
                                compute=TRUE,  
                                link=1),  
        control.inla=list(int.strategy="eb",  
                           strategy="gaussian"),  
        verbose=FALSE)
```






Histogram of resid



Exercice ?

- Ajout de covariables au modèle (i.e. prédicteurs linéaires comme variable explicative)
- Evaluation/comparaison de modèles
- Passage à un modèle spatio-temporel
- Construction d'un modèle intégré (plusieurs sources de données)

Quelques références utiles






R-Inla peut paraître difficile à prendre en main (background mathématique, formatage de la donnée, construction de la matrice d'observation A et construction des cartes de prédiction)

→ Pas tant que ça...

→ Sinon le package Inlabru a pour but de rendre plus accessible l'outil d'inférence INLA

Quelques références utiles






R-Inla peut paraître difficile à prendre en main (background mathématique, formatage de la donnée, construction de la matrice d'observation A et construction des cartes de prédiction)

→ Pas tant que ça...

→ Sinon le package `Inlabru` a pour but de rendre plus accessible l'outil d'inférence INLA

Quelques références utiles






R-Inla peut paraître difficile à prendre en main (background mathématique, formatage de la donnée, construction de la matrice d'observation A et construction des cartes de prédiction)

→ Pas tant que ça...

→ Sinon le package `Inlabru` a pour but de rendre plus accessible l'outil d'inférence INLA

Quelques références utiles



R-Inla peut paraître difficile à prendre en main (background mathématique, formatage de la donnée, construction de la matrice d'observation A et construction des cartes de prédiction)

→ Pas tant que ça...

→ Sinon le package Inlabru a pour but de rendre plus accessible l'outil d'inférence INLA